

Anexo 1 – Registro de Tratamiento de Datos

Proyecto: Trabajo Final de Máster (TFM)

Investigador responsable: Juan Diego Ruiz Valverde

Entidad académica: Universidad (facultad correspondiente)

Fecha: Julio 2026

1. Finalidad del tratamiento

El corpus de tweets se utiliza exclusivamente con fines académicos en el marco del Trabajo Final de Máster. El objetivo es analizar patrones lingüísticos y sociales relacionados con el Mundial FIFA 2022. No se persigue la identificación de usuarios individuales ni la explotación comercial de los datos.

2. Base legal

El dataset proviene de información publicada en una plataforma abierta (Twitter/X). El tratamiento se justifica por interés académico y científico, conforme a la normativa universitaria y principios de investigación responsable.

3. Medidas de anonimización

- Eliminación de columnas sensibles: id, name, screen_name, location.
- Generación de identificador interno (tweet_id_hashed) mediante hash SHA-256 de full_text + created_at.
- Exclusión de información geográfica irregular y potencialmente identificable.
- Corpus final contiene únicamente texto del tweet, metadatos básicos y métricas de interacción.

4. Tratamiento de emojis

Como parte de las medidas de normalización aplicadas al corpus, se implementó un diccionario de mapeo de emojis a categorías semánticas. El objetivo es preservar la carga emocional y contextual que los usuarios transmiten mediante emojis, evitando

su pérdida durante el preprocesamiento. Este mapeo convierte cada emoji en una etiqueta textual representativa (ej. 😊 → “feliz”, 😞 → “triste”), lo que permite que los modelos posteriores integren estas señales en el análisis de sentimiento y clasificación.

La siguiente tabla resume las categorías definidas y los emojis asociados:

Categoría	Emojis incluidos	Palabra asignada
Feliz / humor	😊 😄 🤡 🤩 🤪 🦴	feliz
Tristeza	😞 😭 😔	triste
Enojo	😡 🤬 😠 😡	enojado
Amor / afecto	❤️ 🥰 😍 🥰	amor
Celebración	🥳	celebracion
Incomodidad	😓	incomodo
Nerviosismo	😬	nervioso
Vergüenza	🙈 😳	verguenza
Ironía / sarcasmo	🐸 😏	ironia / sarcasmo
Desagrado / burla	💩 🤢 🤡	apesta / ridículo
Indiferencia	👉 😐	desinteresado / indiferencia
Motivación	💪	motivado
Reconocimiento	👏	reconocimiento
Duda	😕	duda
Coquetería	😘 😏	coqueto

Categoría	Emojis incluidos	Palabra asignada
Sorpresa / impacto	 	sorprendido / impactado
Súplicas / ternura		suplica
Inocencia		inocente
Popularidad	 	popular / sobresaliente

Ejemplo práctico de tratamiento de emojis

Tweet original (antes del preprocesamiento):

Estoy demasiado feliz     #Mundial2022

Después del preprocesamiento (con mapeo de emojis y normalización de hashtags):

estoy demasiado feliz feliz feliz amor popular mundial2022

- Los emojis  se mapearon a la palabra “feliz”.
- El emoji  se mapearon a “amor”.
- El emoji  se mapearon a “popular”.
- El hashtag #Mundial2022 se normalizó a “mundial2022”.
- Se aplicó normalización Unicode y conversión a minúsculas.

5. Responsables del tratamiento

- **Investigador principal:** Juan Diego Ruiz Valverde.
- **Supervisión académica:** Director/a del TFM y la Universidad.

6. Plazos de conservación

El corpus se conservará únicamente durante la duración del TFM. Posteriormente será eliminado o almacenado en repositorio institucional seguro, según normativa académica.

7. Medidas de seguridad

- Almacenamiento en repositorio privado con control de acceso.
- Generación de checksum SHA-256 para garantizar integridad de los archivos.
- Documentación de criterios de inclusión/exclusión en metadata_ingest.yml.