

EVALUACIÓN DE IMPACTO EN LA PROTECCIÓN DE DATOS (DPIA)

Análisis de sentimiento en redes sociales aplicado al Mundial FIFA 2022

Autor: Juan Diego Ruiz Valverde — UNIR 2026

Fecha de elaboración: Junio 2026

1. Descripción del tratamiento

Responsable del tratamiento: Juan Diego Ruiz Valverde, estudiante del Máster en Análisis y Visualización de Datos Masivos / Visual Analytics and Big Data, Universidad Internacional de La Rioja (UNIR).

Finalidad: Análisis de sentimiento de publicaciones en español relacionadas con la Copa Mundial de la FIFA 2022, con fines exclusivamente académicos y de investigación. Los resultados se utilizan para validar un prototipo metodológico reproducible y no tienen ningún uso comercial ni operativo.

Naturaleza de los datos tratados: Texto de publicaciones realizadas voluntariamente en la plataforma X (anteriormente Twitter) por usuarios que las hicieron públicas. El corpus proviene de un dataset abierto de acceso libre. No se tratan categorías especiales de datos en el sentido del artículo 9 del RGPD (salud, origen racial, creencias, etc.).

Categorías de interesados: Usuarios de la plataforma X que publicaron tweets en español relacionados con el Mundial FIFA 2022 durante el 11 de diciembre de 2022.

Volumen de datos: 6.437 tweets en español, filtrados a partir de 99.014 registros crudos.

Origen de los datos: Dataset abierto descargado de Kaggle bajo términos de uso académico. Los datos fueron recopilados originalmente por terceros mediante la API pública de Twitter/X en el momento en que esa recopilación era técnicamente viable.

2. Necesidad y proporcionalidad del tratamiento

Base jurídica: Interés legítimo en investigación científica y académica, amparado en el artículo 6.1.e) y el artículo 89 del RGPD, que permite el tratamiento de datos para fines de investigación científica con las salvaguardas técnicas y organizativas adecuadas. En el contexto de Costa Rica, el tratamiento se justifica bajo el artículo 5.b) de la Ley N.º 8968, que admite el tratamiento sin consentimiento cuando los datos son de acceso público y el fin es legítimo y proporcional.

Proporcionalidad: El tratamiento se limita estrictamente a lo necesario para los fines académicos declarados. Se aplica el principio de minimización de datos: se eliminan todos los campos que no son necesarios para el análisis (nombre, identificador de usuario, localización, URL del perfil) y solo se conservan los campos analíticamente relevantes. No se realizan cruces con otras fuentes de datos ni se elaboran perfiles individuales.

Legitimidad del uso de datos públicos: Las publicaciones analizadas fueron realizadas de forma voluntaria y pública por sus autores en una plataforma abierta. Aun así, el tratamiento se realiza con las salvaguardas descritas en este documento para garantizar que el análisis no comprometa los derechos de los interesados.

3. Identificación y evaluación de riesgos

Riesgo	Probabilidad	Impacto	Nivel	Medida de mitigación
Reidentificación de usuarios a partir del texto del tweet	Media	Alto	Alto	Hashing SHA-256 de identificadores; eliminación de nombres, @usuarios y URLs; resultados publicados solo de forma agregada
Exposición de opiniones individuales sensibles	Baja	Medio	Medio	Análisis exclusivamente agregado; el explorador del corpus no muestra identificadores de usuario
Uso secundario no autorizado de los artefactos publicados	Baja	Medio	Medio	Corpus publicado bajo CC-BY 4.0; código bajo MIT License
Acceso no autorizado al repositorio	Muy baja	Bajo	Bajo	Solo artefactos procesados y anonimizados se suben a GitHub; ningún dato crudo con identificadores
Sesgo algorítmico en el etiquetado automático	Media	Medio	Medio	Dos modelos anotadores independientes; acuerdo inter-sistema $\kappa = 0.6356$; limitaciones documentadas en el TFM
Retención innecesaria de datos intermedios	Baja	Bajo	Bajo	Ficheros intermedios eliminados tras generar el corpus canónico; solo se publican artefactos finales

4. Medidas técnicas y organizativas aplicadas

4.1. Anonimización

Los identificadores de usuario originales se sustituyen por hashes SHA-256 generados a partir del texto del tweet y la fecha de creación (tweet_id_hashed). Este proceso se implementa en ingest.py y es irreversible en condiciones normales.

4.2. Minimización

Se eliminan las columnas id, name, screen_name y location desde la fase de ingestuón. Solo se conservan los campos necesarios para el análisis:

- full_text — texto original del tweet
- created_at — fecha y hora de publicación
- lang — idioma detectado
- retweet_count, favorite_count — métricas de interacción

- followers_count, friends_count — métricas de la cuenta
- source — dispositivo utilizado
- tweet_id_hashed — identificador anonimizado mediante SHA-256

4.3. Agregación en visualizaciones

El dashboard interactivo muestra exclusivamente datos agregados. Las visualizaciones (serie temporal, distribución por sentimiento, nube de palabras, distribución por dispositivo) no permiten identificar usuarios individuales. El explorador del corpus muestra texto limpio sin identificadores.

4.4. Control de acceso y publicación

El repositorio de GitHub es público pero contiene únicamente artefactos procesados y anonimizados. El dataset crudo original no se versiona ni se sube al repositorio. El corpus procesado se publica en Zenodo (DOI: <https://doi.org/10.5281/zenodo.20726879>) con metadatos que documentan el proceso de anonimización.

4.5. Trazabilidad

Todos los pasos del pipeline generan logs y checksums verificables almacenados en logs/ y en data/checksum.txt. El valor del checksum SHA-256 del corpus canónico es: e97da11f850e569f7e326cff61ed63ad9b9f9fa0dea74d5edcf634bf0fe12bb9.

4.6. Retención

Los ficheros intermedios generados durante el preprocesamiento que puedan contener información no completamente anonimizada se eliminan una vez generado el corpus canónico verificado. Los artefactos publicados son los únicos que se conservan a largo plazo.

5. Consulta a interesados y supervisión

Dado el carácter académico del tratamiento y el uso de datos públicos ya recopilados, no se requiere consulta previa a los interesados. El tratamiento se realiza bajo la supervisión del director del TFM (Félix Ladstätter, UNIR) y cumple con las directrices institucionales en materia de investigación con datos de terceros.

En Costa Rica, la autoridad competente en materia de protección de datos es la Agencia de Protección de Datos de los Habitantes (PRODHAB, <https://www.prodhav.go.cr>). Este tratamiento, al realizarse con datos públicos con fines académicos y con las salvaguardas descritas, no requiere notificación previa a la PRODHAB, aunque el presente documento queda disponible como evidencia de cumplimiento.

6. Conclusión

La evaluación concluye que el tratamiento de datos descrito en este proyecto presenta un nivel de riesgo residual bajo tras la aplicación de las medidas técnicas y organizativas implementadas. El análisis se limita a datos públicos, se realiza con fines académicos legítimos, aplica anonimización desde la primera fase del pipeline y publica únicamente resultados agregados. No se identifican riesgos altos que no estén mitigados por las medidas descritas.

El tratamiento es compatible con el RGPD (artículos 6.1.e y 89), la LOPDGDD y la Ley N.º 8968 de Costa Rica (artículo 5.b).

Responsable del tratamiento:

Juan Diego Ruiz Valverde — Estudiante TFM, UNIR

Fecha: Junio 2026

Revisado por:

Félix Ladstätter — Director TFM, UNIR